

Caso de Estudio 01

Análisis Exploratorio de Ventas

Informe Técnico

Javier Barillas

Agosto 2026

Versión 1.0

Contents

Resumen Ejecutivo

Descripción del estudio

Banco Capital GT desea comprender el comportamiento de los saldos de las cuentas de sus clientes durante el año 2025. La gerencia busca identificar patrones temporales, diferencias entre sucursales, segmentos de clientes y productos financieros con el propósito de obtener información que apoye la toma de decisiones comerciales y la gestión de su cartera de clientes.

Objetivo del análisis

Analizar el comportamiento de los saldos bancarios registrados durante el año 2025 mediante técnicas de análisis exploratorio de datos para identificar patrones, diferencias entre segmentos de clientes y oportunidades que contribuyan a la toma de decisiones.

Información general del conjunto de datos

cliente_id		fecha	agencia	edad	segmento	ingreso	saldo	producto	grupo_edad
0	1	2025-11-01 00:00:00	Quetzaltenango	25	Premium	3819.00	24522.72	3503.06	25-29
1	2	2025-11-01 00:00:00	Zona 10	65	Joven	20870.00	35735.08	6087.75	65-69
2	3	2025-04-01 00:00:00	Petén	50	Adulto	22726.00	32879.64	5221.01	50-54
3	4	2025-08-01 00:00:00	Quetzaltenango	55	Premium	12115.00	25499.88	4787.35	55-59
4	5	2025-06-01 00:00:00	Zona 10	35	Joven	8094.00	29405.95	8315.87	35-39
...	...	...	...	...	...	...	...	...	...
995	996	2025-02-01 00:00:00	Escuintla	55	Adulto	27776.00	24017.37	5162.19	55-59
996	997	2025-09-01 00:00:00	Quetzaltenango	47	Joven	26273.00	751.93	3162.52	45-49
997	998	2025-05-01 00:00:00	Petén	53	Adulto	19075.00	46664.96	5981.30	50-54
998	999	2025-09-01 00:00:00	Quetzaltenango	65	Adulto	18186.00	28385.92	8494.76	65-69
999	1000	2025-11-01 00:00:00	Escuintla	58	Adulto	18484.00	37629.65	7083.28	55-59

Table 1: Resultado de la variable: `table`

Mostrando las primeras 5 y últimas 5 filas de un total de 1,000 registros $\times$ 9 variables.

Metodología

El análisis se desarrolló siguiendo un flujo estructurado que comprendió una evaluación inicial de la calidad de los datos, procesos de limpieza y transformación mediante MySQL, una

validación posterior del conjunto de datos preparado y, finalmente, el desarrollo del análisis exploratorio utilizando Python. Los resultados fueron documentados automáticamente y consolidados en el presente informe técnico.

El desarrollo detallado de los resultados, las conclusiones y las recomendaciones derivadas del análisis se presentan en los capítulos posteriores.

1 Introducción

1.1 Contexto

Banco Capital GT desea comprender el comportamiento de los saldos de las cuentas de sus clientes durante el año 2025. La gerencia busca identificar patrones temporales, diferencias entre sucursales, segmentos de clientes y productos financieros con el propósito de obtener información que apoye la toma de decisiones comerciales y la gestión de su cartera de clientes.

1.2 Propósito del informe

El presente documento tiene como finalidad presentar de forma estructurada el proceso de análisis desarrollado sobre el conjunto de datos seleccionado. El informe documenta las etapas de preparación de los datos, la metodología aplicada, los resultados obtenidos para responder las preguntas de análisis y las principales conclusiones y recomendaciones derivadas del estudio.

1.3 Estructura del informe

El informe se organiza en los siguientes capítulos:

- Descripción del conjunto de datos.
- Metodología utilizada durante el análisis.
- Preparación y transformación de los datos.
- Resultados del análisis organizados por cada una de las preguntas planteadas.
- Principales hallazgos.
- Conclusiones.
- Recomendaciones.
- Anexos con información complementaria.

2 Objetivos

Analizar el comportamiento de los saldos bancarios registrados durante el año 2025 mediante técnicas de análisis exploratorio de datos para identificar patrones, diferencias entre segmentos de clientes y oportunidades que contribuyan a la toma de decisiones.

Objetivos Específicos

- Evaluar la calidad y consistencia del conjunto de datos mediante la identificación de valores faltantes, registros duplicados y posibles inconsistencias.
- Analizar el comportamiento de las variables de interés utilizando estadísticas descriptivas y visualizaciones.
- Identificar patrones, tendencias y relaciones relevantes entre las variables analizadas.
- Responder las preguntas planteadas mediante técnicas de análisis de datos.
- Documentar los principales hallazgos, conclusiones y recomendaciones derivados del estudio.

3 Descripción del Conjunto de Datos

3.1 Origen del conjunto de datos

El presente análisis se realizó utilizando un conjunto de datos correspondiente al caso de estudio seleccionado. La información fue obtenida a partir de una fuente estructurada, posteriormente sometida a procesos de limpieza y transformación, y finalmente utilizada para desarrollar el análisis presentado en este informe.

3.2 Resumen del conjunto de datos

cliente_id		fecha	agencia	edad	segmento	ingreso	saldo	producto	grupo_edad
0	1	2025-11-01 00:00:00	Quetzaltenango	25	Premium	3819.00	24522.72	3503.06	25-29
1	2	2025-11-01 00:00:00	Zona 10	65	Joven	20870.00	35735.08	6087.75	65-69
2	3	2025-04-01 00:00:00	Petén	50	Adulto	22726.00	32879.64	5221.01	50-54
3	4	2025-08-01 00:00:00	Quetzaltenango	55	Premium	12115.00	25499.88	4787.35	55-59
4	5	2025-06-01 00:00:00	Zona 10	35	Joven	8094.00	29405.95	8315.87	35-39
...	...	...	...	...	...	...	...	...	...
995	996	2025-02-01 00:00:00	Escuintla	55	Adulto	27776.00	24017.37	5162.19	55-59
996	997	2025-09-01 00:00:00	Quetzaltenango	47	Joven	26273.00	751.93	3162.52	45-49
997	998	2025-05-01 00:00:00	Petén	53	Adulto	19075.00	46664.96	5981.30	50-54
998	999	2025-09-01 00:00:00	Quetzaltenango	65	Adulto	18186.00	28385.92	8494.76	65-69
999	1000	2025-11-01 00:00:00	Escuintla	58	Adulto	18484.00	37629.65	7083.28	55-59

Table 3.1: Resultado de la variable: `table`

Mostrando las primeras 5 y últimas 5 filas de un total de 1,000 registros $\times$ 9 variables.

3.3 Observaciones iniciales

La tabla anterior presenta un resumen representativo del conjunto de datos empleado durante el análisis. En los capítulos posteriores se describen los procedimientos de preparación de los datos y los resultados obtenidos a partir de las preguntas planteadas.

4 Metodología

El presente estudio fue desarrollado siguiendo un flujo de trabajo estructurado orientado a garantizar la calidad de los datos y la correcta documentación del proceso de análisis. La metodología integra herramientas para la preparación, exploración, análisis y presentación de resultados, permitiendo obtener un informe técnico reproducible.

4.1 Herramientas utilizadas

Durante el desarrollo del análisis se emplearon las siguientes herramientas:

- MySQL para la limpieza, transformación y preparación del conjunto de datos.
- Python como lenguaje principal para el análisis de datos.
- Pandas y NumPy para el procesamiento y manipulación de la información.
- Bokeh para la elaboración de visualizaciones.
- Jupyter Notebook para el desarrollo del análisis.
- L^AT_EX para la generación del informe técnico final.

4.2 Flujo metodológico

El proceso de trabajo se desarrolló mediante las siguientes etapas:

1. Obtención del conjunto de datos.
2. Evaluación inicial mediante un análisis exploratorio (EDA) para conocer el estado de la información.
3. Limpieza, transformación y preparación de los datos utilizando MySQL.
4. Exportación del conjunto de datos preparado.
5. Validación del conjunto de datos mediante un segundo análisis exploratorio.

6. Desarrollo del análisis para responder las preguntas planteadas.
7. Generación automática de tablas, figuras y textos empleados en el informe.
8. Elaboración del informe técnico en $\text{\LaTeX}$.

5 Preparación y Transformación de los Datos

El conjunto de datos utilizado en este estudio fue sometido a un proceso de preparación previo al análisis con el propósito de garantizar su calidad, consistencia y adecuación para responder las preguntas planteadas. Esta etapa fue desarrollada utilizando MySQL como sistema gestor de bases de datos.

5.1 Preparación del conjunto de datos

Durante esta fase se realizaron actividades de revisión y validación de la información disponible con el fin de identificar posibles inconsistencias que pudieran afectar el análisis posterior.

5.2 Limpieza de los datos

El proceso de limpieza comprendió la corrección de inconsistencias, el tratamiento de registros duplicados cuando fue necesario, la validación de valores faltantes y la estandarización de los formatos de las variables utilizadas durante el análisis.

5.3 Transformaciones realizadas

Posteriormente se efectuaron las transformaciones necesarias para obtener un conjunto de datos preparado para el análisis. Estas transformaciones incluyeron la creación de nuevas variables cuando fue requerido, conversiones de tipos de datos, normalización de formatos y cualquier otra adecuación necesaria según las características del caso de estudio.

5.4 Conjunto de datos preparado

Una vez finalizado el proceso de preparación y transformación, el conjunto de datos fue exportado y validado mediante un análisis exploratorio adicional para confirmar que la in-

formación se encontraba en condiciones adecuadas para el desarrollo del análisis presentado en este informe.

6 Resultados del Análisis

En este capítulo se presentan los resultados obtenidos para cada una de las preguntas planteadas durante el estudio. Cada apartado incluye la pregunta de análisis, la evidencia obtenida mediante tablas y visualizaciones, así como la interpretación correspondiente de los resultados.

6.1 Pregunta 1

¿Cómo evolucionó el saldo total administrado por el banco durante 2025?

	fecha	saldo	fecha_str
0	2025-01-01 00:00:00	1659555.47	01-01-2025
1	2025-02-01 00:00:00	2413002.99	01-02-2025
2	2025-03-01 00:00:00	2326675.34	01-03-2025
3	2025-04-01 00:00:00	1877667.33	01-04-2025
4	2025-05-01 00:00:00	2027743.77	01-05-2025
...	...	...	...
7	2025-08-01 00:00:00	2127324.14	01-08-2025
8	2025-09-01 00:00:00	1895080.98	01-09-2025
9	2025-10-01 00:00:00	1839979.38	01-10-2025
10	2025-11-01 00:00:00	2144329.81	01-11-2025
11	2025-12-01 00:00:00	2551370.28	01-12-2025

Table 6.1: Resultado de la variable: `table_ques1`
Mostrando las primeras 5 y últimas 5 filas de un total de 12 registros $\times$ 3 variables.



Figure 6.1: Visualización correspondiente a la pregunta 1.

Análisis

La evolución mensual de los saldos bancarios durante 2025 evidencia un comportamiento caracterizado por fluctuaciones a lo largo del período analizado. El saldo total administrado por el banco oscila entre aproximadamente Q1.79 millones y Q2.55 millones, registrándose el valor más alto en el mes de diciembre, lo que representa una variación cercana a Q800 mil entre el valor mínimo y el máximo observado. No se identifica una tendencia sostenida de crecimiento o disminución durante el año. En su lugar, los saldos presentan variaciones mensuales que podrían estar asociadas a factores estacionales o a cambios en el comportamiento financiero de los clientes. El incremento registrado en diciembre podría estar relacionado con eventos propios de la época, como el pago de aguinaldos, bonos, remesas o un mayor dinamismo de la actividad económica. No obstante, confirmar estas hipótesis requeriría incorporar información adicional, como indicadores macroeconómicos o campañas comerciales desarrolladas por la institución durante el mismo período.

6.2 Pregunta 2

¿Qué sucursales concentran el mayor saldo de los clientes?

	agencia	saldo
0	Zona 10	4713085.48
1	Cobán	4803674.04
2	Quetzaltenango	4920131.86
3	Escuintla	5152377.07
4	Petén	5338387.17

Table 6.2: Resultado de la variable: `table_ques2`
Conjunto completo de datos: 5 registros $\times$ 2 variables.



Figure 6.2: Visualización correspondiente a la pregunta 2.

Análisis

La distribución del saldo total administrado por las agencias presenta diferencias moderadas entre las cinco sucursales analizadas. La agencia de Petén concentra el mayor volumen de saldos, con aproximadamente Q5.34 millones, mientras que la agencia ubicada en Zona 10 registra el menor saldo agregado, con alrededor de Q4.71 millones. La diferencia entre ambas asciende a aproximadamente Q500 mil, lo que representa una variación relativamente reducida considerando el volumen total administrado por cada sucursal. En términos generales, no se observa una concentración significativa de los saldos en una única agencia. Los resultados reflejan una distribución relativamente equilibrada entre las sucursales, lo que sugiere que la cartera de clientes y los recursos administrados no dependen de forma predominante de una sola ubicación geográfica. Un aspecto que merece un análisis más de-

tallado es que las agencias ubicadas fuera del área metropolitana presentan niveles de saldos comparables e incluso superiores a la sucursal de Zona 10. Este comportamiento podría estar asociado a diversos factores, como la composición de la cartera de clientes, la presencia de actividades económicas relevantes en dichas regiones, el nivel de bancarización o estrategias comerciales específicas implementadas por la institución. No obstante, la información disponible no permite establecer una relación causal, por lo que sería necesario incorporar variables adicionales para explicar este patrón con mayor precisión.

6.3 Pregunta 3

¿Qué segmentos de clientes concentran los mayores saldos?

	segmento	saldo
0	Adulto	8012228.33
1	Joven	8339027.73
2	Premium	8576399.56

Table 6.3: Resultado de la variable: `table_ques3`
Conjunto completo de datos: 3 registros $\times$ 2 variables.



Figure 6.3: Visualización correspondiente a la pregunta 3.

Análisis

La distribución del saldo por segmento de clientes muestra una composición relativamente equilibrada entre los tres grupos analizados. El segmento Premium concentra el mayor volumen de saldos, con aproximadamente Q8.58 millones, seguido por el segmento Joven con Q8.34 millones y, finalmente, el segmento Adulto, con alrededor de Q8.01 millones. La diferencia entre el segmento con mayor y menor saldo es cercana a Q500 mil, lo que evidencia una variación moderada entre ellos. En términos generales, no se observa una concentración marcada de los saldos en un único segmento de clientes. Los resultados reflejan una distribución relativamente homogénea, lo que sugiere que el banco mantiene una cartera diversificada y que su volumen de recursos administrados no depende exclusivamente de un perfil específico de clientes. Aunque el segmento Premium registra el mayor saldo agregado, la diferencia respecto a los demás segmentos es reducida. Este comportamiento podría indicar que las estrategias de captación y retención de clientes han logrado una distribución equilibrada de los recursos entre los distintos perfiles. Sin embargo, para comprender las causas de esta distribución sería necesario complementar el análisis con información adicional, como el número de clientes por segmento, el saldo promedio por cliente y la evolución temporal de cada grupo.

6.4 Pregunta 4

¿Existe una relación entre el ingreso de los clientes y el saldo disponible en sus cuentas?

	cliente_id	ingreso	saldo	segmento
0	1	3819.00	24522.72	Premium
1	2	20870.00	35735.08	Joven
2	3	22726.00	32879.64	Adulto
3	4	12115.00	25499.88	Premium
4	5	8094.00	29405.95	Joven
...	...	...	...	...
995	996	27776.00	24017.37	Adulto
996	997	26273.00	751.93	Joven
997	998	19075.00	46664.96	Adulto
998	999	18186.00	28385.92	Adulto
999	1000	18484.00	37629.65	Adulto

Table 6.4: Resultado de la variable: `table_ques4`

Mostrando las primeras 5 y últimas 5 filas de un total de 1,000 registros $\times$ 4 variables.



Figure 6.4: Visualización correspondiente a la pregunta 4.

Análisis

El análisis de la relación entre el ingreso de los clientes y el saldo disponible en sus cuentas no evidencia un patrón lineal claramente definido. La dispersión de las observaciones muestra que clientes con niveles de ingreso similares pueden presentar saldos considerablemente diferentes y, de igual forma, clientes con ingresos elevados no necesariamente mantienen los saldos más altos. Este comportamiento se observa tanto en el conjunto de datos como al diferenciar los registros por segmento de clientes. La distribución de los datos sugiere que el nivel de ingreso, por sí solo, no constituye un factor suficiente para explicar el compor-

tamiento de los saldos bancarios. La ausencia de una tendencia claramente definida indica que podrían intervenir otros elementos que no se encuentran representados en la base de datos, tales como los hábitos de ahorro, la antigüedad del cliente, el uso de productos financieros, la actividad económica o características particulares de cada cliente. A partir de este resultado, sería recomendable complementar el análisis mediante técnicas estadísticas, como el cálculo del coeficiente de correlación o la estimación de un modelo de regresión, con el fin de cuantificar la intensidad de la relación entre ambas variables y evaluar si esta resulta estadísticamente significativa. Asimismo, la incorporación de variables adicionales permitiría desarrollar un análisis multivariado que explique con mayor precisión los factores asociados al comportamiento de los saldos bancarios.

6.5 Pregunta 5

¿Qué grupos de edad concentran el mayor saldo administrado por el banco durante 2025?

	grupo_edad	saldo
0	15-19	790852.56
1	20-24	2666010.58
2	25-29	2407436.99
3	30-34	2179591.76
4	35-39	2146435.52
...	...	...
7	50-54	2626315.58
8	55-59	2144247.86
9	60-64	2701876.70
10	65-69	2327534.66
11	70-74	464016.31

Table 6.5: Resultado de la variable: `table_qes5`

Mostrando las primeras 5 y últimas 5 filas de un total de $12 \text{ registros} \times 2 \text{ variables}$.



Figure 6.5: Visualización correspondiente a la pregunta 5.

Análisis

La distribución de los saldos por rango de edad durante 2025 muestra que la mayor concentración de recursos se encuentra en los clientes con edades comprendidas entre 20 y 69 años. En estos grupos, el saldo agregado oscila entre aproximadamente Q2.15 millones y Q2.70 millones, evidenciando una distribución relativamente homogénea entre las diferentes etapas de la vida laboral. Por el contrario, los grupos ubicados en los extremos de la distribución, correspondientes a clientes de 15 a 19 años y de 70 a 74 años, registran los menores niveles de saldo, con montos aproximados entre Q464 mil y Q790 mil. La diferencia respecto a los grupos de mayor concentración resulta considerable, lo que sugiere una menor partici-

pación de estos rangos de edad en el volumen total de recursos administrados por el banco. Este comportamiento es consistente con el ciclo de vida financiero de los clientes, ya que las edades comprendidas entre los 20 y 69 años suelen concentrar una mayor participación en el mercado laboral y, por consiguiente, una mayor capacidad para generar y mantener saldos en sus cuentas. No obstante, esta interpretación constituye una hipótesis de negocio y requeriría información adicional, como el número de clientes por rango de edad, el saldo promedio por cliente y otras variables socioeconómicas, para ser validada.

7 Conclusiones

En este capítulo se presentan las principales conclusiones derivadas del análisis realizado. Estas sintetizan los resultados obtenidos durante el estudio y responden a las preguntas planteadas, destacando los aspectos más relevantes identificados en el conjunto de datos.

El saldo total administrado por el banco durante 2025 presentó fluctuaciones mensuales, sin evidenciar una tendencia sostenida de crecimiento o disminución a lo largo del período analizado. La distribución de los saldos entre las diferentes sucursales fue relativamente equilibrada, sin observarse una concentración significativa en una única agencia. Las diferencias identificadas entre sucursales fueron moderadas en relación con el volumen total administrado. De forma similar, los segmentos de clientes mostraron una distribución homogénea del saldo agregado, lo que sugiere que la cartera del banco se encuentra diversificada y no depende exclusivamente de un único perfil de clientes. El análisis de dispersión no evidenció una relación lineal claramente definida entre el ingreso de los clientes y el saldo disponible en sus cuentas, lo que indica que el nivel de ingreso, por sí solo, no explica el comportamiento de los saldos observados. La mayor concentración de saldos se registró en los clientes con edades comprendidas entre 20 y 69 años, mientras que los grupos de menor y mayor edad presentaron una participación considerablemente menor en el saldo total administrado.